

Avaliação Experimental de Heurísticas e Meta-Heurísticas para o Problema Fracionário de Seleção de Pedidos Ótima

Vinicius Alves Pereira

Orientador: Prof. Ms. Eduardo Gabriel Reis Miranda

Coorientador: Prof. Dr. André Luiz Maravilha Silva

Centro Federal de Educação Tecnológica de Minas Gerais
Campus Divinópolis

2026

Roteiro

- 1 **Introdução e Motivação**
- 2 **Referencial Teórico**
- 3 **Definição do Problema**
- 4 **Metodologia**
- 5 **Resultados**
- 6 **Discussão e Limitações**
- 7 **Conclusão e Próximos Passos**

Contexto: E-commerce e Centros de Distribuição

- Crescimento acelerado do e-commerce impõe demandas operacionais sem precedentes sobre centros de distribuição
- Etapa de **picking** é a mais onerosa do armazém, concentrando parcela expressiva de custos e tempo
- Reduções mesmo modestas no deslocamento repercutem diretamente na eficiência da cadeia de suprimentos

Order Batching Problem (OBP)

- Agrupar pedidos em waves coletadas em uma única viagem
- Problema NP-difícil
- Amplamente estudado

Origem do Problema: Desafio SBPO 2025 / Mercado Livre

- **Mercado Livre** (maior *marketplace* da América Latina) propôs o desafio no âmbito do **57º SBPO 2025**
- Define o **Problema de Seleção de Pedidos Ótima (PSP)**: selecionar pedidos e corredores para maximizar

$$\frac{\text{unidades coletadas}}{\text{corredores visitados}}$$

- Instâncias geradas pela própria empresa, refletindo cenários reais de operação
- **Gap na literatura**: nenhum trabalho reúne abordagens distintas com comparação estatística sistemática considerando qualidade e tempo

Heurísticas Construtivas

O que são?

Procedimentos aproximados que obtêm soluções de boa qualidade em tempo reduzido, **sem garantia de otimalidade**.

Características:

- Constroem a solução em *uma única passagem*
 - Decisões locais guiadas por critério guloso
 - Sem revisão das escolhas já feitas
- ⇒ Rápidas, porém limitadas em qualidade

Exemplo — mochila gulosa:

Ordenar itens por v_i/w_i decrescente.

Pode falhar:

$W=10$, itens (1, 2) e (10, 15)

Gulosa → valor **2**

Ótimo → valor **15**

Meta-heurísticas

O que são?

Métodos que coordenam busca local com estratégias de alto nível — capazes de **escapar de ótimos locais** e explorar robustamente o espaço de soluções.

Conceitos centrais:

- **Vizinhança** — soluções próximas
- **Busca local** — move-se para vizinho melhor
- **Intensificação** × **Diversificação**

Famílias principais:

- *Trajetória*: Busca Tabu, GRASP, Simulated Annealing, VNS
- *Populacionais*: Algoritmos Genéticos, Colônia de Formigas

Qualidade sensivelmente superior às heurísticas construtivas — ao

Fronteira de Pareto — Definição


Dominância de Pareto

x domina y se é *não pior* em todos os objetivos **e** estritamente melhor em ao menos um. Soluções não dominadas formam a **Fronteira de Pareto**.

Neste trabalho: dois objetivos a minimizar — *gap* relativo $\times$ tempo (s)

Config.	Status	Gap (%)	Tempo (s)
C_1	Pareto-ótima	8,0	0,5
C_2	Pareto-ótima	4,0	1,2
C_3	Pareto-ótima	1,5	4,0
C_4	Dominada por C_2	5,5	2,0
C_5	Dominada por C_1	9,0	1,0

Fronteira de Pareto — Exemplo



- Pontos em destaque (C_1 , C_2 , C_3) — **não dominados**
- C_4 e C_5 — dominados; a curva tracejada delimita a fronteira
- Cada ponto da fronteira é um *trade-off* diferente: melhorar um

Programação Fracionária Inteira e Dinkelbach

Programação Fracionária Inteira (PFI)

Função objetivo é a **razão de dois lineares**:

$$\max \quad \frac{f(x)}{g(x)}, \quad x \in S, \quad g(x) > 0$$

Com variáveis inteiras $\Rightarrow$ **NP-difícil**. Não é linearizável diretamente para um solver MILP.

Método de Dinkelbach — referência para PFC II

Parametriza pelo subproblema $F(\lambda) = \max_{x \in S} f(x) - \lambda g(x)$ e itera $\lambda_{k+1} = f(x_k)/g(x_k)$:

- Cada iteração resolve um **MILP ordinário**
- Convergência **superlinear** ao ótimo

O Problema de Seleção de Pedidos Ótima (PSP)

Dados: backlog de pedidos, estoque nos corredores, limites $[LB, UB]$

Decidir simultaneamente:

- 1 Subconjunto de pedidos $\mathcal{O}' \subseteq \mathcal{O}$ que compõe a *wave*
- 2 Subconjunto de corredores $\mathcal{A}' \subseteq \mathcal{A}$ a visitar

Maximizar (Programação Fracionária Inteira — NP-difícil):

$$\max \frac{\sum_{o \in \mathcal{O}'} \sum_{i \in \mathcal{I}_o} u_{oi}}{|\mathcal{A}'|}$$

Restrições:

- $LB \leq \sum u_{oi} x_o \leq UB$ — tamanho mínimo e máximo da *wave*
- Viabilidade física: os corredores visitados devem cobrir toda a demanda

Exemplo Numérico — Três Soluções Viáveis

Instância com 5 pedidos, 5 itens, 5 corredores; $LB = 5$, $UB = 12$

Solução	$\mathcal{O}'$	$\mathcal{A}'$	Unidades	Objetivo
A	$\{0, 4\}$	$\{0, 1\}$	5	$5/2 = 2,5$
B	$\{0, 2, 3\}$	$\{1, 3, 4\}$	12	$12/3 = 4,0$
C	$\{0, 1, 2, 4\}$	$\{1, 3\}$	10	$10/2 = 5,0$

Lição central

Mais pedidos **não** garante maior objetivo. A produtividade depende de *concentrar* a demanda em **poucos corredores**. Solução C é ótima para esta instância.

Heurística Gulosa Parametrizável — Visão Geral

Estrutura em duas etapas

- 1 **Seleção de pedidos:** percorre a sequência definida pelos parâmetros; aceita pedidos enquanto respeita UB e o estoque agregado
- 2 **Seleção de corredores:** dado o conjunto de pedidos, determina os corredores que cobrem toda a demanda

Parâmetros principais:

<code>order</code>	critério de ordenação dos pedidos
<code>greedy</code>	estratégia de seleção de corredores
<code>first_order</code>	pedido de referência (similaridade)

Critérios de Ordenação de Pedidos (7)

- `desc` — decrescente por volume
- `asc` — crescente por volume
- `random` — aleatório
- `similar` — Jaccard crescente
- `diff` — Jaccard decrescente
- `similar_weighted` — Jaccard pond.
- `diff_weighted` — Jaccard pond. dec.

Estratégias de corredores (3):

- `simple` — pontuação estática
- `multi` — pontuação dinâmica (recalculada a cada iteração)
- `exact` — CP-SAT (OR-Tools): minimiza $|\mathcal{A}'|$ por PL inteira

Protocolo Experimental — Fase 1

Dataset A


- 20 instâncias de porte variado (5 pedidos até 12.402 pedidos)
- 5 réplicas por variação → replicabilidade de componentes aleatórios

Gap relativo (MSC):

$$\text{gap} = 1 - \frac{f}{f^*}$$

f^* = melhor solução conhecida
(SBPO 2025)

Filtragem — Pareto bidimensional:



Experimentos — Protocolo das Duas Fases

Fase 1 — Filtragem (PFC I)

- **Dataset A:** 20 instâncias de menor porte
- **5 réplicas** por variação
- Objetivo: identificar variações promissoras
- Critério: Fronteira de Pareto ($gap \times tempo$)

Fase 2 — Avaliação (PFC II)

- **Datasets B e X:** instâncias de maior porte
- Candidatos selecionados + novos algoritmos
- Análise estatística formal (ANOVA, IC)

Métricas coletadas por (variação, instância):

Gap relativo


$gap = (f^* - f) / f^*$ — média e DP sobre 5 réplicas

Tempo de execução

média e DP em segundos sobre 5 réplicas


Agregação final: média das médias por instância (20 instâncias) + 1

Visão Geral — 57 Variações no Espaço Gap × Tempo



- Variações A4, A5 e A6 — **canto inferior esquerdo**: menor gap e menor tempo
- Dispersão clara entre estratégias de corredor

Impacto da Estratégia de Corredores no Tempo



exact (CP-SAT)

0,43 a 0,64 s


multi

< 0,35 s

simple

< 0,35 s


Impacto do Critério de Ordenação na Qualidade



● desc — separação **clara**: gap 0,69–0,70

● asc — gap 0,76–0,78 (pior)

Fronteira de Pareto — Três Variações Não Dominadas



ID	Variação	Gap	Tempo (s)
A4	simple_desc_exact	0,6907	0,43
A5	simple_desc_multi	0,6938	0,28

A4 vs. A5 vs. A6 — Diferença está nos Corredores

As três variações compartilham `order = desc`: selecionam **exatamente os mesmos pedidos** em cada instância.

A qualidade diferente é determinada *apenas* pelos corredores:

Instância	A4 Corr.	A5 Corr.	A6 Corr.
instance_0001	13	13	13
instance_0003	23	24	25
instance_0005	125	125	129
instance_0010	275	280	296
instance_0014	373	374	378

A4 (exact/CP-SAT) minimiza o número de corredores globalmente $\Rightarrow$ maior objetivo. Custo: tempo até $4\times$ maior que A6.

Discussão dos Resultados

Gaps de 0,69–0,78: patamar esperado

Heurísticas construtivas puras constroem a solução em uma única passagem — sem busca local ou refinamento iterativo. As soluções capturam $\approx 22\text{--}31\%$ da qualidade das MSC. Objetivo da Fase 1: *filtrar comparativamente*, não estabelecer benchmark absoluto.

Ordenação desc — principal fator de qualidade

Priorizar pedidos volumosos maximiza as unidades incorporadas à wave nas primeiras iterações, quando o estoque ainda está intacto. Lógica gulosa naturalmente alinhada ao objetivo fracionário.

Limitações:

- Resultados restritos ao *dataset A* (menor porte)
- Sem testes de significância estatística formal

Conclusão — PFC I

Objetivos cumpridos integralmente:

- 1 Formalização do PSP e enquadramento na literatura do OBP
- 2 Implementação da heurística gulosa com **57 variações** (7 critérios $\times$ 3 estratégias de corredores)
- 3 Identificação das configurações Pareto-ótimas: **A4, A5 e A6**

Resultado central

A ordenação decrescente (*desc*) é o fator dominante na qualidade. A estratégia de corredores opera um **trade-off controlável**: de A6 (rápido) a A4 (melhor qualidade), todos não dominados pela fronteira de Pareto.

Próximos Passos — PFC II

1 Heurísticas por seleção de corredores

Definir primeiro os corredores e depois selecionar os pedidos — inversão da ordem de decisão

2 Meta-heurísticas

Busca Tabu, GRASP e Algoritmos Genéticos aplicados sobre as soluções construtivas para superar ótimos locais e reduzir os gaps absolutos

3 Fase 2 — Datasets B e X com análise estatística

Avaliação de A4, A5 e A6 junto aos novos métodos em instâncias de maior porte, com testes de significância, intervalos de confiança e ANOVA

Obrigado!

Vinicius Alves Pereira

Orientador: Prof. Ms. Eduardo Gabriel Reis Miranda

Coorientador: Prof. Dr. André Luiz Maravilha Silva

Centro Federal de Educação Tecnológica de Minas Gerais
Campus Divinópolis — 2026